

Giải thích công thức và ý nghĩa các chỉ số đánh giá

Real-time Fraud Detection — Kafka → Spark (LSTM) → PostgreSQL

Ghi chú:

- Lớp positive (dương tính) = gian lận (fraud = 1); legitimate = 0.
- Các chỉ số được tính trong evaluate/evaluate_realtime.py (dùng scikit-learn).

1. Ma trận nhầm lẫn (Confusion Matrix)

Ký hiệu	Tên tiếng Anh	Ý nghĩa
TP	True Positive	Thực sự gian lận và được dự đoán gian lận (đúng)
FP	False Positive	Thực sự hợp lệ nhưng bị dự đoán gian lận (báo động sai)
TN	True Negative	Thực sự hợp lệ và được dự đoán hợp lệ (đúng)
FN	False Negative	Thực sự gian lận nhưng bị dự đoán hợp lệ (bỏ sót)

- Tổng: TP + FP + FN + TN = tổng số giao dịch.
- FP = báo oan khách hàng; FN = lọt gian lận (thường nguy hiểm hơn).

2. Các chỉ số phân loại

Accuracy (Độ chính xác tổng thể)

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

Ý nghĩa: tỉ lệ dự đoán ĐÚNG trên toàn bộ giao dịch.

Hạn chế với fraud: dữ liệu rất mất cân bằng (gian lận chỉ ~0.7%), nên mô hình đoán tất cả là hợp lệ cũng đạt ~99.7% Accuracy. Vì vậy Accuracy KHÔNG đủ để đánh giá mô hình fraud.

Precision (Độ chính xác, đo trên nhãn fraud)

$$\text{Precision} = TP / (TP + FP)$$

Ý nghĩa: trong số những giao dịch bị CẢNH BÁO là gian lận, bao nhiêu phần trăm ĐÚNG là gian lận.

Trả lời câu hỏi: Báo động của ta đáng tin đến đâu?

Recall (Độ phủ / Độ nhạy)

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

Ý nghĩa: trong số những giao dịch THỰC SỰ gian lận, ta BẮT ĐƯỢC bao nhiêu phần trăm.

Trả lời câu hỏi: Ta bỏ sót bao nhiêu gian lận?

F1-score

$$\text{F1} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

Ý nghĩa: trung bình điều hòa của Precision và Recall, cân bằng giữa ít báo động sai và ít bỏ sót gian lận trong MỘT con số.

F1 cao chỉ khi cả Precision và Recall cùng cao.

FPR (False Positive Rate — Tỷ lệ dương giả)

$$\text{FPR} = \text{FP} / (\text{FP} + \text{TN})$$

Ý nghĩa: trong số giao dịch THỰC SỰ HỢP LỆ, bao nhiêu phần trăm bị BÃO NHẦM là gian lận.

Đây là tỉ lệ báo động oan trên khách hàng hợp lệ; trong fraud càng thấp càng tốt.

3. Chỉ số theo xác suất / xếp hạng

Các chỉ số này KHÔNG phụ thuộc ngưỡng 0.7 mà dùng trực tiếp FRAUD_PROBABILITY để đánh giá khả năng xếp hạng của mô hình.

ROC-AUC

- Ý nghĩa: khả năng mô hình XẾP HẠNG một giao dịch gian lận cao hơn một giao dịch hợp lệ.
- AUC = 1.0 là hoàn hảo; 0.5 là đoán ngẫu nhiên.
- AUC = 0.972 nghĩa là: nếu lấy ngẫu nhiên 1 gian lận + 1 hợp lệ, xác suất mô hình chấm gian lận cao hơn là 97.2%.
- Đường ROC vẽ TPR (= Recall) theo FPR khi thay đổi ngưỡng.

Average Precision (AP)

$$\text{AP} = \sum_i (\text{recall}[i] - \text{recall}[i-1]) \times \text{precision}[i]$$

- Ý nghĩa: DIỆN TÍCH dưới đường Precision-Recall; là trung bình có trọng số của Precision tại từng ngưỡng (trọng số = mức tăng Recall).
- AP phù hợp hơn ROC-AUC khi dữ liệu mất cân bằng nặng (như fraud), vì nó tập trung vào lớp positive (gian lận).

Precision@K (Precision@50 / @100 / @200)

$$\text{P@k} = (\text{số giao dịch gian lận trong top-k}) / k$$

Cách tính:

- Xếp toàn bộ giao dịch theo FRAUD_PROBABILITY giảm dần.
- Lấy k giao dịch đáng nghi nhất (xác suất cao nhất).
- $P@k$ = số giao dịch thực sự gian lận trong k giao dịch đó chia cho k.

Ý nghĩa thực tế: nếu nhóm điều tra chỉ xem k giao dịch đáng nghi nhất mỗi ngày, $P@k$ cho biết tỉ lệ trúng gian lận trong k giao dịch đó.

4. Chỉ số độ trễ (Latency) — ms

Dùng cho cả Prediction latency (thời gian LSTM inference) và End-to-end latency (từ producer đến PostgreSQL sink).

Trung bình (Average)

$$\text{Average} = (1/n) \times \sum x_i$$

Ý nghĩa: độ trễ bình quân. Nhạy với outlier rất lớn, nên thường không phản ánh đúng cảm nhận thông thường.

P50 (Median — trung vị)

- Giá trị mà 50% mẫu có độ trễ $\leq$ giá trị này.
- Ý nghĩa: độ trễ điển hình mà phần lớn giao dịch gặp phải. Chịu nhiễu tốt hơn trung bình.

P95

- Giá trị mà 95% mẫu có độ trễ $\leq$ giá trị này (5% chậm nhất bị loại khi nhìn vào P95).
- Ý nghĩa: phản ánh trải nghiệm của nhóm chậm nhưng chưa quá cực đoan.

P99

- Giá trị mà 99% mẫu có độ trễ $\leq$ giá trị này (chỉ 1% chậm hơn).
- Ý nghĩa: đo trường hợp xấu gần như tệ nhất; dùng để cam kết SLO (ví dụ: 99% giao dịch xử lý dưới X ms).

Min / Max

- Min: độ trễ NHỎ NHẤT quan sát được.
- Max: độ trễ LỚN NHẤT quan sát được (thường là outlier; nếu Max lớn bất thường so với P99 thì có vài giao dịch bị kẹt/backlog).

Cách tính percentile trong code (nội suy tuyến tính):

$$\text{index} = (\text{len}(\text{values}) - 1) \times p / 100.0$$

nội suy giữa $\text{values}[\text{floor}(\text{index})]$ và $\text{values}[\text{ceil}(\text{index})]$

5. Ví dụ thực tế (cấu hình 50 tx/s)

Chỉ số	Giá trị	Độc nhanh
Accuracy	0.997	cao nhưng ít ý nghĩa vì dữ liệu lệch
Precision	0.936	trong 100 cảnh báo có ~94 đúng
Recall	0.633	bắt được ~63% gian lận thật
F1	0.755	cân bằng P/R khá tốt
FPR	0.00031	chỉ ~0.03% khách hợp lệ bị báo oan
ROC-AUC	0.972	xếp hạng rất tốt
Average Precision	0.805	tốt trên dữ liệu lệch
Precision@50/100/200	1.0	top giao dịch đáng nghi nhất đều trúng
Prediction P50/P95/P99	27 / 205 / 914 ms	đa số nhanh, 1% chậm nhất ~0.9s
E2E P50/P95/P99	14755 / 23385 / 54535 ms	độ trễ toàn pipeline còn cao

6. Vì sao số dự đoán gian lận khác nhau giữa 50 / 100 / 500 tx/s?

Cấu hình	Tổng giao dịch	Gian lận thực tế (TX_FRAUD)	Dự đoán gian lận	TP	FN	FP
50 tx/s	500.000	3.592	2.429	2.273	1.319	156
100 tx/s	500.000	3.592	2.429	2.273	1.319	156
500 tx/s	500.000	3.592	2.425	2.269	1.323	156

1) Gian lận THỰC TẾ (TX_FRAUD) giống nhau — vì sao?

TX_FRAUD là nhãn ground-truth cố định trong các file .pkl. Producer chỉ replay lại đúng cùng một tập 500.000 giao dịch, nên số gian lận thực tế luôn là 3.592 ở cả 3 lần chạy.

2) Dự đoán gian lận (FRAUD_PREDICTION) là kết quả của pipeline streaming có trạng thái, phụ thuộc THỨ TỰ xử lý:

- feature_engineering.py: tính feature cửa sổ (số giao dịch, giá trị trung bình, rủi ro terminal 1/7/30 ngày) từ state customer_state / terminal_state cộng dồn theo thứ tự xử lý.
- lstm_inference.py: xây chuỗi 5 giao dịch gần nhất của cùng khách hàng (customer_history, deque maxlen=5) → LSTM → xác suất → so ngưỡng 0.7.
- Cả hai stage đều chỉ sắp xếp theo TX_DATETIME TRONG PHẠM VI từng micro-batch, còn state/history thì cộng dồn XUYỀN SUỐT các batch.

3) Vì sao đổi tốc độ producer làm thay đổi dự đoán?

Producer gửi vào một partition duy nhất (partition=0) theo thứ tự thời gian, nhưng Spark đọc theo micro-batch (maxOffsetsPerTrigger = 20.000). Ở 50 tx/s mỗi batch có ít giao dịch; ở 500 tx/s mỗi batch có rất nhiều và pipeline không đuổi kịp (thực tế ~308 tx/s) nên sinh backlog lớn. Khi các giao dịch bị chia vào micro-batch khác nhau, thứ tự toàn cục và nội dung state mà

mỗi giao dịch nhìn thấy lệch nhẹ → feature/chuỗi LSTM của vài giao dịch thay đổi nhẹ → xác suất thay đổi nhẹ → lật qua ngưỡng 0.7.

4) Vì sao chỉ lệch vài giao dịch?

Mô hình LSTM chạy eval(), không dropout → deterministic với cùng input. Chỉ những giao dịch có xác suất NẪM SẮT ngưỡng 0.7 mới bị đổi nhãn khi feature/chuỗi thay đổi nhẹ. Ở 500 tx/s: 4 giao dịch chuyển từ TP thành FN (TP 2.273 → 2.269), FP giữ nguyên 156 — tức chỉ các trường hợp biên bị ảnh hưởng, mô hình vẫn rất ổn định.

5) Bằng chứng rõ nhất:

- 50 tx/s và 100 tx/s cho kết quả GIỐNG HẸT nhau (2.429; TP 2.273) dù tốc độ khác nhau → tốc độ không làm đổi dữ liệu; dữ liệu replay cùng thứ tự nên thứ tự được bảo toàn.
- 500 tx/s (chạy ngày khác, tải nặng, backlog lớn, micro-batch bị gộp tối đa) làm thứ tự/nhóm batch lệch đi đủ để 4 dự đoán biên bị đổi.

Tóm lại: TX_FRAUD giống nhau vì đó là nhãn cố định của cùng 500.000 giao dịch; còn FRAUD_PREDICTION khác nhau (rất nhỏ) vì dự đoán là kết quả của pipeline streaming có trạng thái và phụ thuộc thứ tự xử lý, mà thứ tự/nhóm micro-batch thay đổi theo tốc độ producer.

File được sinh tự động bằng python-docx, phục vụ giải thích các độ đo của pipeline real-time fraud detection.