

TRƯỜNG ĐẠI HỌC VINUNI
CHƯƠNG TRÌNH AI THỰC CHIẾN 2026 - KHÓA 2

PHẠM THỊ THẨM
Mã số học viên: 2A202600789

BÁO CÁO MÔ HÌNH DỰ ĐOÁN
GIAN LẬN TRONG GIAO DỊCH

Chương 1

DỮ LIỆU GIAO DỊCH

1.1 Lựa Chọn Thiết Kế Dữ Liệu

Tập trung vào những đặc điểm cốt yếu nhất của một giao dịch, về cơ bản giao dịch bằng thẻ thanh toán bao gồm bất kỳ khoản tiền nào mà khách hàng thanh toán cho đơn vị chấp nhận thẻ tại một thời điểm nhất định. Do đó, sáu đặc điểm chính tóm tắt một giao dịch bao gồm [1]:

- ID giao dịch: Mã định danh duy nhất của giao dịch.
- Ngày và giờ: Thời điểm diễn ra giao dịch.
- ID khách hàng: Mã định danh của khách hàng. Mỗi khách hàng có một mã định danh duy nhất.
- ID thiết bị đầu cuối (terminal): Mã định danh của đơn vị chấp nhận thanh toán (hay chính xác hơn là của thiết bị đầu cuối). Mỗi thiết bị đầu cuối có một mã định danh duy nhất.
- Số tiền giao dịch: Giá trị của giao dịch.
- Nhân gian lận: Một biến nhị phân, với giá trị 0 cho giao dịch hợp lệ hoặc giá trị 1 cho giao dịch gian lận.

1.1. LỰA CHỌN THIẾT KẾ DỮ LIỆU

Các thuộc tính này sẽ được gọi là TRANSACTION_ID, TX_DATETIME, CUSTOMER_ID, TERMINAL_ID, TX_AMOUNT và TX_FRAUD.

TRANSACTION_ID	TX_DATETIME	CUSTOMER_ID	TERMINAL_ID	TX_AMOUNT	TX_FRAUD
0	2018-04-01 00:00:31	596	3156	57.16	0
1	2018-04-01 00:02:10	4961	3412	81.51	0
2	2018-04-01 00:07:56	2	1365	146.00	0
...	...	...	...	...	...

Hình 1.1: Ví dụ về bảng giao dịch đã được gán nhãn. Mỗi giao dịch được thể hiện dưới dạng một hàng trong bảng, đi kèm với nhãn của nó (biến TX_FRAUD: 0 cho giao dịch hợp lệ và 1 cho giao dịch gian lận).


Quá trình mô phỏng sẽ bao gồm năm bước chính:

- Tạo hồ sơ khách hàng: Mỗi khách hàng có thói quen chi tiêu khác nhau. Điều này sẽ được mô phỏng bằng cách xác định một số thuộc tính cho từng khách hàng. Các thuộc tính chính bao gồm vị trí địa lý, tần suất chi tiêu và số tiền chi tiêu. Thông tin về khách hàng sẽ được thể hiện dưới dạng một bảng, được gọi là bảng hồ sơ khách hàng.
- Tạo hồ sơ thiết bị đầu cuối: Thuộc tính của thiết bị đầu cuối chỉ đơn giản bao gồm vị trí địa lý. Thông tin về thiết bị sẽ được thể hiện dưới dạng một bảng, được gọi là bảng hồ sơ thiết bị đầu cuối.
- Liên kết hồ sơ khách hàng với thiết bị đầu cuối: Chúng ta sẽ giả định rằng khách hàng chỉ thực hiện giao dịch trên các thiết bị nằm trong một bán kính nhất định tính từ vị trí địa lý của họ. Giả định đơn giản này có nghĩa là khách hàng chỉ giao dịch tại các thiết bị nằm gần vị trí của họ về mặt địa lý. Bước này bao gồm việc thêm một trường dữ liệu có tên 'list_terminals' (danh sách thiết bị) vào hồ sơ của mỗi khách hàng, chứa tập hợp các thiết bị mà khách hàng đó có thể sử dụng.
- Tạo giao dịch: Chương trình mô phỏng sẽ duyệt qua tập hợp các hồ sơ khách hàng và tạo ra các giao dịch dựa trên thuộc tính của họ (tần suất và số tiền

1.1. LỰA CHỌN THIẾT KẾ DỮ LIỆU

chi tiêu, cũng như các thiết bị khả dụng). Kết quả thu được sẽ là một bảng dữ liệu giao dịch.

- Tạo các kịch bản gian lận: Bước cuối cùng này sẽ gán nhãn cho các giao dịch là hợp lệ (chính chủ) hoặc gian lận. Việc này được thực hiện dựa trên ba kịch bản gian lận khác nhau.



Hình 1.2: Quy trình tạo giao dịch. Hồ sơ khách hàng và thiết bị đầu cuối được sử dụng để tạo ra một tập hợp các giao dịch. Bước cuối cùng, tạo ra các kịch bản gian lận, sẽ cung cấp bảng dữ liệu giao dịch đã được gán nhãn.

1.1.1.1 Tạo hồ sơ khách hàng

Mỗi khách hàng sẽ được xác định bởi các thuộc tính sau:

- CUSTOMER_ID: Mã định danh duy nhất của khách hàng.
- (x_customer_id, y_customer_id): Cặp tọa độ thực ($x_{customer_id}$, $y_{customer_id}$) trên lưới 100 x 100, xác định vị trí địa lý của khách hàng.
- (mean_amount, std_amount): Giá trị trung bình và độ lệch chuẩn của các khoản tiền giao dịch của khách hàng, với giả định rằng các khoản tiền này tuân theo phân phối chuẩn.
- mean_nb_tx_per_day: Số lượng giao dịch trung bình mỗi ngày của khách hàng, với giả định rằng số lượng giao dịch mỗi ngày tuân theo phân phối Poisson. Giá trị này sẽ được lấy ngẫu nhiên từ phân phối đều trong khoảng (0, 4).

1.1. LỰA CHỌN THIẾT KẾ DỮ LIỆU

	CUSTOMER_ID	x_customer_id	y_customer_id	mean_amount	std_amount	mean_nb_tx_per_day
0	0	54.881350	71.518937	62.262521	31.131260	2.179533
1	1	42.365480	64.589411	46.570785	23.285393	3.567092
2	2	96.366276	38.344152	80.213879	40.106939	2.115580
3	3	56.804456	92.559664	11.748426	5.874213	0.348517
4	4	2.021840	83.261985	78.924891	39.462446	3.480049

Hình 1.3: Ví dụ một bảng hồ sơ khách hàng cho 5 giao dịch đầu tiên.

1.1.2 Tạo hồ sơ đầu cuối (terminal)

Mỗi terminal sẽ được xác định bởi các thuộc tính sau:

- **TERMINAL_ID**: Mã định danh của terminal.
- **(x_terminal_id, y_terminal_id)**: Cặp tọa độ thực ($x_{customer_id}$, $y_{customer_id}$) trên lưới 100 x 100, xác định vị trí địa lý của terminal.

	TERMINAL_ID	x_terminal_id	y_terminal_id
0	0	54.881350	71.518937
1	1	60.276338	54.488318
2	2	42.365480	64.589411
3	3	43.758721	89.177300
4	4	96.366276	38.344152

Hình 1.4: Ví dụ một bảng thiết bị đầu cuối của khách hàng cho 5 thiết bị.

1.1.3 Liên kết hồ sơ khách hàng với các thiết bị đầu cuối

Trong thiết kế, khách hàng chỉ có thể thực hiện giao dịch trên các thiết bị đầu cuối nằm trong bán kính r tính từ vị trí địa lý của họ. :

1.1. LỰA CHỌN THIẾT KẾ DỮ LIỆU

CUSTOMER_ID	x_customer_id	y_customer_id	mean_amount	std_amount	mean_nb_tx_per_day	available_terminals
0	54.881350	71.518937	62.262521	31.131260	2.179533	[0, 1, 2, 3]
1	42.365480	64.589411	46.570785	23.285393	3.567092	[0, 1, 2, 3]
2	96.366276	38.344152	80.213879	40.106939	2.115580	[1, 4]
3	56.804456	92.559664	11.748426	5.874213	0.348517	[0, 1, 2, 3]
4	2.021840	83.261985	78.924891	39.462446	3.480049	[2, 3]

Hình 1.5: Với $r = 50$

1.1.4 Tạo giao dịch

Hồ sơ khách hàng hiện đã chứa đầy đủ thông tin cần thiết để tạo các giao dịch. Tiến hành tạo một bảng giao dịch tuân theo định dạng đã nêu ở trên.

	TX_DATETIME	CUSTOMER_ID	TERMINAL_ID	TX_AMOUNT	TX_TIME_SECONDS	TX_TIME_DAYS
0	2018-04-01 07:19:05	0	3	123.59	26345	0
1	2018-04-01 19:02:02	0	3	46.51	68522	0
2	2018-04-01 18:00:16	0	0	77.34	64816	0
3	2018-04-02 15:13:02	0	2	32.35	141182	1
4	2018-04-02 14:05:38	0	3	63.30	137138	1
...	...	...	...	...	...	...
60	2018-04-05 07:41:19	4	2	111.38	373279	4
61	2018-04-05 06:59:59	4	3	80.36	370799	4
62	2018-04-05 17:23:34	4	2	53.25	408214	4
63	2018-04-05 12:51:38	4	2	36.44	391898	4
64	2018-04-05 12:38:46	4	3	17.53	391126	4

Hình 1.6: Một tập hợp gồm 65 giao dịch, với 5 khách hàng, 5 thiết bị đầu cuối và 5 ngày.

Tạo một tập dữ liệu bao gồm:

- 5.000 khách hàng.
- 10.000 thiết bị đầu cuối.
- Dữ liệu giao dịch trong 183 ngày (tương ứng với khoảng thời gian mô phỏng

1.1. LỰA CHỌN THIẾT KẾ DỮ LIỆU

từ ngày 01/04/2018 đến 30/09/2018).

- Bán kính $r = 5$, tương ứng với khoảng 100 thiết bị đầu cuối khả dụng cho mỗi khách hàng.

Bảng 1.1: Ví dụ dữ liệu giao dịch được sinh bởi bộ mô phỏng

TRANSACTION _ID	TX _DATETIME	CUSTOMER _ID	TERMINAL _ID	TX _AMOUNT	TX_TIME _SECONDS	TX_TIME _DAYS
0	2018-04-01 00:00:31	596	3156	57.16	31	0
1	2018-04-01 00:02:10	4961	3412	81.51	130	0
2	2018-04-01 00:07:56	2	1365	146.00	476	0
3	2018-04-01 00:09:29	4128	8737	64.49	569	0
4	2018-04-01 00:10:34	927	9906	50.99	634	0
⋮						
1754150	2018-09-30 23:56:36	161	655	54.24	15810996	182
1754151	2018-09-30 23:57:38	4342	6181	1.23	15811058	182
1754152	2018-09-30 23:58:21	618	1502	6.62	15811101	182
1754153	2018-09-30 23:59:52	4056	3067	55.40	15811192	182
1754154	2018-09-30 23:59:57	3542	9849	23.59	15811197	182

1.1.5 Tạo các kịch bản gian lận

Bước cuối cùng của quá trình mô phỏng này bổ sung các giao dịch gian lận vào tập dữ liệu, dựa trên các kịch bản gian lận sau:

- Kịch bản 1: Mọi giao dịch có giá trị lớn hơn 220 đều được coi là gian lận. Kịch bản này không dựa trên tình huống thực tế mà nhằm tạo ra một mô hình gian lận rõ ràng, có thể dễ dàng bị phát hiện bởi bất kỳ hệ thống phát hiện gian lận cơ bản nào. Điều này hữu ích cho việc kiểm chứng cách triển khai kỹ thuật phát hiện gian lận.
- Kịch bản 2: Mỗi ngày, một danh sách gồm hai thiết bị đầu cuối được chọn ngẫu nhiên. Tất cả các giao dịch thực hiện trên các thiết bị này trong 28 ngày tiếp theo sẽ bị đánh dấu là gian lận. Kịch bản này mô phỏng việc tội phạm sử dụng thiết bị đầu cuối, chẳng hạn như thông qua hình thức lừa đảo trực tuyến (phishing). Việc phát hiện kịch bản này có thể thực hiện được bằng cách bổ sung các đặc trưng (features) để theo dõi số lượng giao dịch gian lận trên thiết bị. Do thiết bị chỉ bị xâm nhập trong vòng 28 ngày, cần

1.1. LỰA CHỌN THIẾT KẾ DỮ LIỆU

thiết kế thêm các chiến lược xử lý hiện tượng "trôi dạt khái niệm" (concept drift) để giải quyết hiệu quả kịch bản này.

- Kịch bản 3: Mỗi ngày, một danh sách gồm 3 khách hàng được chọn ngẫu nhiên. Trong 14 ngày tiếp theo, 1/3 số giao dịch của họ sẽ bị nhân giá trị lên gấp 5 lần và bị đánh dấu là gian lận. Kịch bản này mô phỏng hành vi gian lận trong giao dịch không cần thẻ vật lý (card-not-present) khi thông tin xác thực của khách hàng đã bị lộ. Khách hàng vẫn tiếp tục thực hiện các giao dịch, trong khi kẻ gian lận thực hiện các giao dịch có giá trị cao hơn nhằm tối đa hóa lợi ích bất chính. Việc phát hiện kịch bản này đòi hỏi phải bổ sung các tính năng theo dõi thói quen chi tiêu của khách hàng. Đối với kịch bản 2, do thẻ chỉ bị xâm phạm tạm thời, cần thiết kế thêm các chiến lược xử lý vấn đề "concept drift" (sự thay đổi bản chất dữ liệu theo thời gian).

Concept drift là hiện tượng mà mối quan hệ giữa dữ liệu đầu vào và nhãn đầu ra thay đổi theo thời gian.

Bổ sung các đặc trưng như:

- Số lượng giao dịch gian lận tại terminal trong 1 ngày gần nhất.
- Số lượng giao dịch gian lận trong 7 ngày gần nhất.
- Tỷ lệ giao dịch gian lận tại terminal.
- Số lượng thẻ bị ảnh hưởng bởi terminal.

Những đặc trưng này giúp mô hình nhanh chóng phát hiện khi một terminal bắt đầu có dấu hiệu bất thường và cũng nhận biết khi terminal đã trở lại hoạt động bình thường.

1.2. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU

1.2 Phân Tích Khám Phá Dữ Liệu

Dữ liệu có 1.754.155 giao dịch (dòng) và 9 cột (thực ra là 7 đặc trưng và 1 cột TRANSACTION_ID giống như số thứ tự cho mỗi dòng dữ liệu và 1 cột TX_FRAUD_SCENARIO là loại kịch bản gian lận). Tổng cộng có 14.681 giao dịch bị đánh dấu là gian lận, chiếm 0,8% tổng số giao dịch.

Và có 5.000 khách hàng, 10.000 thiết bị đầu cuối.

Dữ liệu giao dịch trong 183 ngày (tương ứng với khoảng thời gian mô phỏng từ ngày 01/04/2018 đến 30/09/2018).


Không có giá trị bị thiếu (missing values).

Không có dữ liệu trùng lặp.

	TX_AMOUNT
count	1.754155e+06
mean	5.363230e+01
std	4.232649e+01
min	0.000000e+00
25%	2.101000e+01
50%	4.464000e+01
75%	7.695000e+01
max	2.628000e+03

Hình 1.7: Thống kê mô tả TX_AMOUNT.

1.2. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU




Hình 1.8: Biểu đồ hộp so sánh giá trị giao dịch theo nhãn gian lận

Trong nhiều bài toán hồi quy, outlier thường là dữ liệu nhiễu và có thể bị loại bỏ. Nhưng trong bài toán phát hiện gian lận, những giao dịch có giá trị rất lớn chính là các trường hợp đáng quan tâm, thậm chí có thể là tín hiệu của gian lận.

Theo thống kê mô tả, giá trị giao dịch (TX_AMOUNT) có giá trị trung bình là 53,63, trung vị là 44,64 và độ lệch chuẩn là 42,32. Giá trị giao dịch dao động từ 0 đến 2.628, cho thấy khoảng biến thiên rất lớn. Bên cạnh đó, giá trị trung bình lớn hơn trung vị, cho thấy phân phối của TX_AMOUNT lệch phải (right-skewed) do tồn tại một số giao dịch có giá trị rất cao.


Biểu đồ hộp cho thấy giao dịch gian lận (TX_FRAUD = 1) có khoảng phân bố rộng hơn và xuất hiện nhiều giá trị ngoại lai (outlier) hơn so với giao dịch không gian lận (TX_FRAUD = 0). Các giao dịch gian lận có nhiều trường hợp đạt giá trị từ vài trăm đến trên 2.600, trong khi các giao dịch không gian lận chủ yếu tập trung ở mức giá trị thấp và chỉ xuất hiện rất ít ngoại lai.

1.2. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU



Hình 1.9: Giá trị giao dịch theo thời gian và trạng thái gian lận.

Điều này cho thấy giá trị giao dịch (TX_AMOUNT) là một đặc trưng có khả năng hỗ trợ phân biệt giao dịch gian lận với giao dịch bình thường. Tuy nhiên, vẫn tồn tại sự chồng lấp giữa hai nhóm, tức là không phải mọi giao dịch có giá trị lớn đều là gian lận và ngược lại. Vì vậy, mô hình phát hiện gian lận cần kết hợp thêm các đặc trưng khác như thông tin khách hàng, thiết bị giao dịch và chuỗi giao dịch để nâng cao độ chính xác.




Hình 1.10: Biểu đồ phân phối của các giá trị giao dịch và thời gian giao dịch.

Sự phân bố số tiền giao dịch tập trung chủ yếu ở các khoản tiền nhỏ. Sự phân bố thời gian giao dịch tuân theo phân bố Gaussian hàng ngày, tập trung vào khoảng giữa trưa.

Hãy cùng xem xét sự biến động theo ngày của số lượng giao dịch, số lượng giao dịch gian lận và số lượng thẻ bị xâm phạm.

1.2. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU




Hình 1.11: Sự biến động theo ngày của số lượng giao dịch, số lượng giao dịch gian lận và số lượng thẻ bị xâm phạm.

Quá trình mô phỏng này tạo ra khoảng 10.000 giao dịch mỗi ngày. Số lượng giao dịch gian lận mỗi ngày là khoảng 85, và số lượng thẻ bị gian lận là khoảng 80. Đáng chú ý là số lượng giao dịch gian lận trong tháng đầu tiên thấp hơn; nguyên nhân là do các hành vi gian lận thuộc kịch bản 2 và 3 kéo dài trong khoảng thời gian lần lượt là 28 và 14 ngày.

Bộ dữ liệu thu được rất đáng chú ý: nó thể hiện tình trạng mất cân bằng lớp (các giao dịch gian lận chiếm chưa đến 1%), sự kết hợp giữa các đặc trưng dạng số và dạng phân loại, các mối quan hệ phức tạp giữa các đặc trưng, cùng các kịch bản gian lận biến đổi theo thời gian.


1.2. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU



Hình 1.12: Ma trận tương quan.

TX_AMOUNT có tương quan mạnh hơn với TX_FRAUD.

TX_TIME_SECONDS và TX_TIME_DAYS tương quan hoàn toàn (vì cùng biểu diễn thời gian).



Hình 1.13: Tỷ lệ giao dịch gian lận theo giờ.

Biểu đồ cho thấy, các giao dịch gian lận có tỷ lệ xảy ra vào ban đêm cao hơn ban ngày.

1.2. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU

1.3 Biến Đổi Đặc Trưng Cơ Sở

Bảng 1.2: Feature engineering cho dữ liệu giao dịch

Đặc trưng gốc	Kiểu dữ liệu gốc	Phép biến đổi	Số đặc trưng mới	Kiểu đặc trưng mới
TX_DATETIME	Panda Times-tamp	0 nếu giao dịch diễn ra vào ngày trong tuần, 1 nếu giao dịch diễn ra vào cuối tuần. Đặc trưng mới là TX_DURING_WEEKEND.	1	Integer (0/1)
TX_DATETIME	Panda Times-tamp	0 nếu giao dịch diễn ra trong khoảng từ 06:00 sáng đến 00:00 đêm, 1 nếu giao dịch diễn ra trong khoảng từ 00:00 đêm đến 06:00 sáng. Đặc trưng mới là TX_DURING_NIGHT.	1	Integer (0/1)
CUSTOMER_ID	Categorical	Số lượng giao dịch của khách hàng trong n ngày gần nhất, với $n \in \{1, 7, 30\}$. Các đặc trưng mới có dạng CUSTOMER_ID_NB_TX_nDAY_WINDOW.	3	Integer

Tiếp tục ở trang sau

1.2. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU

Bảng 1.2 – tiếp theo

Đặc trưng gốc	Kiểu dữ liệu	Phép biến đổi	Số đặc trưng mới	Kiểu đặc trưng mới
CUSTOMER_ID	Categorical	Giá trị chi tiêu trung bình của khách hàng trong n ngày gần nhất, với $n \in \{1, 7, 30\}$. Các đặc trưng mới có dạng CUSTOMER_ID_AVG_AMOUNT_nDAY_WINDOW.	3	Real
TERMINAL_ID	Categorical	Số lượng giao dịch trên terminal trong $n + d$ ngày gần nhất, với $n \in \{1, 7, 30\}$ và $d = 7$. Tham số d được gọi là độ trễ và sẽ được thảo luận sau. Các đặc trưng mới được gọi là TERMINAL_ID_NB_TX_nDAY_WINDOW.	3	Integer
TERMINAL_ID	Categorical	Số lượng gian lận trung bình trên thiết bị đầu cuối trong $n + d$ ngày gần nhất, với $n \in \{1, 7, 30\}$ và $d = 7$. Tham số d được gọi là độ trễ và sẽ được thảo luận sau. Các đặc trưng mới được gọi là TERMINAL_ID_RISK_nDAY_WINDOW.	3	Real

Chương 2

PHƯƠNG PHÁP XÂY DỰNG VÀ ĐÁNH GIÁ

2.1 Xác Định Tập Training Và Test


Trong bối cảnh phát hiện gian lận, khoảng thời gian ngăn cách giữa tập training và tập test được gọi là "khoảng thời gian trễ" (delay period) hoặc "độ trễ phản hồi" (feedback delay). Điều này phản ánh thực tế rằng, trong một hệ thống phát hiện gian lận thực tế, nhãn của một giao dịch (gian lận hay hợp lệ) chỉ được xác định sau khi có khiếu nại từ khách hàng hoặc thông qua kết quả điều tra gian lận. Việc ấn định khoảng thời gian trễ là một tuần là cách tiếp cận đơn giản hóa. Cách làm này giả định rằng nhãn (gian lận hay hợp lệ) của tất cả các giao dịch sẽ được xác định chính xác một tuần sau khi chúng diễn ra. Trên thực tế, tình hình lại khác biệt: khoảng thời gian trễ có thể ngắn hơn nếu khách hàng báo cáo gian lận nhanh chóng, hoặc dài hơn nhiều trong những trường hợp gian lận không bị phát hiện suốt nhiều tháng. Trên thực tế, khoảng thời gian trễ là một tham số trong quá trình đánh giá mô hình phát hiện gian lận. Mức trễ một tuần được coi là cơ sở hợp lý ở bước ước tính ban đầu: theo kinh nghiệm, các số liệu thống kê thường cho thấy phần lớn các phản hồi sẽ có

2.2. XÂY DỰNG CHIẾN LƯỢC VALIDATION

sẵn sau khoảng thời gian trễ là một tuần.

2.2 Xây Dựng Chiến Lược Validation

1. Phương pháp xác thực giữ lại (hold-out validation):



Hình 2.1: Phương pháp xác thực giữ lại (hold-out validation).

Chiến lược validation này được gọi là hold-out validation (tách dữ liệu) vì một phần dữ liệu lịch sử được tách ra khỏi tập training.

2. Phương pháp xác thực giữ lại lặp lại (repeated hold-out validation):

Các mô hình dự báo và hiệu suất của chúng thường nhạy cảm với dữ liệu được sử dụng để huấn luyện. Chỉ cần thay đổi đôi chút tập dữ liệu huấn luyện cũng có thể dẫn đến sự khác biệt về mô hình dự báo và hiệu suất.


Một phương án thay thế cho quy trình hold-out validation là huấn luyện các mô hình dự báo khác nhau bằng cách sử dụng các mẫu ngẫu nhiên từ dữ liệu training. Cách tiếp cận này cho phép thu được nhiều ước lượng khác nhau về sai số xác thực (validation error), từ đó xác định được các khoảng tin cậy cho hiệu suất kỳ vọng thay vì chỉ có một ước lượng duy nhất. Quy trình này được gọi là quy trình repeated hold-out validation.

Phương pháp xác thực giữ lại lặp lại (repeated hold-out validation) dựa vào

2.3. CÂN BẰNG DỮ LIỆU TRÊN TRAINING

các tập con ngẫu nhiên của cùng một tập dữ liệu huấn luyện để xây dựng các mô hình dự báo. Một hạn chế của phương pháp này là nó làm giảm hiệu suất kỳ vọng của các mô hình, do chỉ có các tập con của dữ liệu được sử dụng để huấn luyện.

3. **Phương pháp xác thực tuần tự (prequential validation):** bao gồm việc sử dụng các tập huấn luyện có kích thước tương đương, được lấy từ dữ liệu lịch sử trước đó. Ở mỗi lần chia (fold), các tập training và validation được dịch chuyển lùi lại một khối về phía quá khứ.



Hình 2.2: Phương pháp xác thực tuần tự (prequential validation).

Kết Luận: dùng phương pháp xác thực tuần tự (prequential validation) để chạy thử nghiệm.

2.3 Cân Bằng Dữ Liệu Trên Training

Kết hợp kỹ thuật lấy mẫu oversampling và undersampling thông qua SMOTE và random undersampling:

- SMOTE: thực hiện lấy mẫu oversampling đối với lớp thiểu số bằng cách tạo ra các mẫu nhân tạo nằm trong vùng lân cận của các mẫu quan sát

2.4. HIỆU SUẤT ĐÁNH GIÁ SẼ SỬ DỤNG

được. Ý tưởng ở đây là tạo ra các mẫu thuộc nhóm thiểu số mới bằng cách nội suy giữa các mẫu cùng lớp. Quá trình này tạo ra các cụm dữ liệu bao quanh mỗi quan sát thuộc nhóm thiểu số. Thông qua việc tạo ra các quan sát tổng hợp, bộ phân loại sẽ xây dựng được các vùng quyết định rộng hơn, bao hàm cả những mẫu lân cận thuộc nhóm thiểu số.

- Random undersampling (RUS): phương pháp đơn giản nhất giảm số lượng mẫu thuộc lớp đa số, bao gồm việc loại bỏ ngẫu nhiên các mẫu từ lớp đa số cho đến khi đạt được tỷ lệ mất cân bằng mong muốn.

2.4 Hiệu Suất Đánh Giá Sẻ Sử Dụng

Ba chỉ số hiệu suất: AUC ROC, Độ chính xác trung bình (AP) và Độ chính xác thẻ top-k (CP@k) được sử dụng.

- Độ chính xác thẻ top-k (CP@k) (card precision top-k): các điều tra viên chỉ có thể kiểm tra tối đa k thẻ có nguy cơ gian lận mỗi ngày, chỉ số này được tính toán bằng cách xếp hạng các giao dịch có nguy cơ gian lận cao nhất cho mỗi ngày trong tập test, sau đó chọn ra k thẻ có các giao dịch mang xác suất gian lận cao nhất. Sau đó, độ chính xác (precision) (tỷ lệ thẻ thực sự bị xâm phạm trên tổng số thẻ được dự đoán là bị xâm phạm) được tính toán cho mỗi ngày. Chỉ số "card precision top-k" là giá trị trung bình của các độ chính xác theo ngày này. Giá trị k được ấn định là 100 (nghĩa là giả định rằng chỉ có thể kiểm tra 100 thẻ mỗi ngày).
- Độ chính xác trung bình (average precision - AP) là đại lượng thay thế cho độ chính xác top-k, giúp tổng hợp các giá trị độ chính xác cho mọi giá trị k có thể có.
- AUC ROC là một thước đo thay thế cho average precision (độ chính xác trung bình), thước đo vốn chú trọng hơn vào các điểm số đạt được với giá

2.4. HIỆU SUẤT ĐÁNH GIÁ SẼ SỬ DỤNG

trị k cao. Trên thực tế, AUC ROC ít mang lại ý nghĩa thiết thực hơn vì hiệu suất quan trọng nhất thường nằm ở các giá trị k thấp. Báo cáo chỉ số này vì đây là thước đo hiệu suất được sử dụng rộng rãi nhất trong các tài liệu nghiên cứu về phát hiện gian lận.

Chương 3

XÂY DỰNG MODEL

3.1 Sử Dụng Mạng Neural Network Để Phát Hiện Gian Lận

Không có lý do gì để cho rằng mạng thần kinh truyền thẳng đa lớp (multi-layer feed-forward neural network) có thể vượt trội hơn Random Forest hay XGBoost trên các tập dữ liệu tĩnh (static datasets); tuy nhiên, bài toán phát hiện gian lận còn có nhiều tiêu chí quan trọng khác bên cạnh hiệu suất phát hiện.

3.1.1 Học tăng dần

XGBoost và Random Forest đều là các mô hình học máy dạng tập hợp cây (tree ensembles). Nhìn chung, các cây quyết định không hỗ trợ cơ chế học tăng dần (incremental learning) vì chúng cần toàn bộ tập dữ liệu để tính toán các điểm phân tách tối ưu và xây dựng cấu trúc cây. Việc thay đổi một điểm phân tách khi có dữ liệu mới là một bài toán không hề đơn giản. Cụ thể, do cây được xây dựng theo cấu trúc phân cấp, việc cập nhật một điều kiện tại nút phân tách ở tầng trên sẽ trực tiếp làm cho cấu trúc của các cây con bên dưới không còn

3.1. SỬ DỤNG MẠNG NEURAL NETWORK ĐỂ PHÁT HIỆN GIAN LẬN

sử dụng được nữa. Tuy nhiên, cần lưu ý rằng đã có một số kỹ thuật được đề xuất để cập nhật cây theo hướng tăng dần, chẳng hạn như cây Hoeffding, cây Mondrian hay các mô hình tập hợp cây học tăng dần. Mặc dù vậy, các thuật toán dựa trên cây phần lớn vẫn được sử dụng trong kịch bản học theo lô (batch learning).

Học tăng dần (incremental learning) rất hữu ích cho việc phát hiện gian lận vì:

- (1) phương pháp này ít tốn kém tài nguyên hơn do các mô hình có thể được cập nhật thường xuyên dựa trên các phần dữ liệu mới nhất thay vì phải huấn luyện lại toàn bộ từ đầu trên toàn bộ tập dữ liệu.
- (2) nó loại bỏ nhu cầu lưu trữ dữ liệu lịch sử trong thời gian dài, qua đó tránh được các vấn đề liên quan đến quy định về dữ liệu.

Mạng nơ-ron có ưu điểm là mang tính chất tăng dần, do quá trình huấn luyện của chúng diễn ra theo cơ chế lặp và xử lý từng mẫu dữ liệu.

3.1.2 Học biểu diễn và huấn luyện từ đầu - đến cuối

Nhiều nghiên cứu đã chỉ ra rằng, bên cạnh các đặc trưng giao dịch thô, việc sử dụng kỹ thuật thiết kế đặc trưng dựa trên kiến thức chuyên môn (xây dựng các giá trị tổng hợp phù hợp từ lịch sử giao dịch của chủ thẻ) giúp cải thiện đáng kể tỷ lệ phát hiện gian lận.

Tuy nhiên, quy trình này có những hạn chế, chủ yếu là sự phụ thuộc vào kiến thức của chuyên gia con người với chi phí cao. Đã có những nỗ lực nhằm thay thế việc tổng hợp thủ công bằng phương pháp học biểu diễn tự động. Các phương pháp này chủ yếu dựa trên mạng nơ-ron (như mạng tự mã hóa - autoencoder, mạng nơ-ron tích chập và mạng bộ nhớ dài-ngắn hạn - LSTM).

Hơn nữa, bên cạnh các biểu diễn đã học này, việc sử dụng mạng thần kinh truyền thẳng (feed-forward neural network) thay vì XGBoost hay rừng ngẫu

3.1. SỬ DỤNG MẠNG NEURAL NETWORK ĐỂ PHÁT HIỆN GIAN LẬN
nhiên (random forests) mang lại sự thú vị hơn, vì nó cho phép huấn luyện toàn bộ mô hình (bao gồm cả phần biểu diễn và phần phân loại) theo cơ chế "từ đầu đến cuối" (end-to-end).

3.1.3 Học liên kết

Học liên kết (federated learning) bao gồm việc chia sẻ và huấn luyện một mô hình trên nhiều thiết bị, trong đó mỗi thiết bị lưu giữ dữ liệu của riêng mình tại chỗ. Ý tưởng cốt lõi là chia sẻ một mô hình ban đầu giữa các thiết bị, cập nhật mô hình đó tại từng thiết bị, và thường xuyên tổng hợp các bản cập nhật từ tất cả các thiết bị thành một mô hình toàn cục dùng chung. Thông thường, việc cập nhật mô hình toàn cục được thực hiện bằng các phương pháp như trung bình hóa liên kết (federated averaging), tức là tính trung bình có trọng số dựa trên các tham số (trọng số) của từng mô hình cục bộ.

Trái ngược với các mô hình dựa trên cây, các mạng nơ-ron có cùng kiến trúc có thể được tính trung bình trọng số; điều này khiến chúng trở thành lựa chọn hàng đầu trong lĩnh vực học liên kết (federated learning).

3.1.4 Một mô hình bổ sung cho kỹ thuật xếp chồng (stacking)

Mặc dù các mạng thần kinh có thể đạt được hiệu suất tổng thể tương đương với XGBoost hoặc rừng ngẫu nhiên (random forests), điều này không có nghĩa là các mô hình khác nhau này phát hiện ra cùng những mô hình gian lận giống nhau. Cụ thể, các thử nghiệm thường cho thấy việc kết hợp phương pháp dựa trên cây quyết định và mạng thần kinh thành một mô hình tổng hợp (ensemble) đơn giản theo cơ chế lấy trung bình có thể mang lại hiệu suất tổng thể tốt hơn nhờ vào tính đa dạng của chúng.

3.2. XÂY DỰNG MODEL

3.1.5 Thông điệp chính

Bên cạnh hiệu suất phát hiện, mạng nơ-ron còn mang lại nhiều ưu điểm cho bài toán phát hiện gian lận tín dụng: chúng có thể được kết hợp với các mô hình khác, có khả năng huấn luyện tăng dần, dễ dàng triển khai theo mô hình học liên kết (federated learning), cho phép học biểu diễn, cũng như có thể đồng thời học biểu diễn và thực hiện phân loại thông qua quy trình huấn luyện đầu-cuối (end-to-end).

3.2 Xây Dựng Model

Trong lĩnh vực phát hiện gian lận thẻ tín dụng, việc lựa chọn các đặc trưng đóng vai trò then chốt để đạt được kết quả phân loại chính xác. Các chiến lược kỹ thuật đặc trưng (feature engineering) dựa trên phương pháp tổng hợp đặc trưng hiện đang được áp dụng rộng rãi. Phương pháp tổng hợp đặc trưng thiết lập mối liên hệ giữa giao dịch hiện tại và các giao dịch liên quan khác thông qua việc tính toán các chỉ số thống kê dựa trên các biến số của chúng.


Việc sử dụng phương pháp tổng hợp đặc trưng để phát hiện gian lận là một phần của hướng nghiên cứu được gọi là "phát hiện gian lận có tính đến ngữ cảnh" (context-aware fraud detection); trong đó, các yếu tố ngữ cảnh (ví dụ: lịch sử giao dịch của chủ thẻ) gắn liền với giao dịch sẽ được xem xét để đưa ra quyết định. Cách tiếp cận này cho phép, chẳng hạn như, cung cấp thông tin chi tiết về các đặc điểm của giao dịch so với thói quen mua sắm thường thấy của chủ thẻ và/hoặc thiết bị đầu cuối - những thông tin vốn mang ý nghĩa quan trọng về mặt trực quan.

3.2.1 Phát hiện gian lận có nhận biết ngữ cảnh

Bối cảnh được xác định dựa trên một biến mốc - thường là Mã khách hàng (Customer ID) trong hầu hết các trường hợp. Cụ thể, quy trình bắt đầu bằng

3.2. XÂY DỰNG MODEL

việc xây dựng chuỗi các giao dịch lịch sử - được sắp xếp theo trình tự thời gian từ cũ nhất đến gần đây nhất - có cùng giá trị biến mốc với giao dịch hiện tại.



Hình 3.1: Phát hiện gian lận có nhận biết ngữ cảnh.


Toàn bộ chuỗi dữ liệu này đóng vai trò là nền tảng cơ sở cho các phương pháp tiếp cận có tính đến ngữ cảnh. Thực tế, quy trình tổng quát dựa trên việc xây dựng các đặc trưng hoặc biểu diễn mới cho mỗi giao dịch cụ thể, dựa vào chuỗi ngữ cảnh gắn liền với giao dịch đó. Tuy nhiên, các phương pháp này có thể được chia thành hai nhóm chính: nhóm thứ nhất (biểu diễn dựa trên chuyên gia) dựa vào kiến thức chuyên môn để thiết lập các quy tắc và xây dựng cơ chế tổng hợp đặc trưng; nhóm thứ hai (biểu diễn tự động) tập trung vào các chiến lược trích xuất đặc trưng tự động sử dụng các mô hình học sâu (deep learning).

Kinh nghiệm chuyên gia

Để xây dựng các đặc trưng dựa trên kiến thức chuyên gia (expert features) từ chuỗi dữ liệu gốc, trước tiên người ta áp dụng một lớp chọn lọc dựa trên các ràng buộc chuyên môn (ví dụ: cùng mã danh mục người bán, cùng quốc gia, giao

3.2. XÂY DỰNG MODEL

dịch diễn ra trong vòng một tuần gần nhất, v.v.) để thu được một chuỗi con cụ thể hơn. Sau đó, một hàm tổng hợp (như tổng, trung bình, v.v.) được tính toán dựa trên các giá trị của một đặc trưng đã chọn (ví dụ: số tiền giao dịch) trong chuỗi con đó. Các đặc trưng chuyên gia không nhất thiết có thể áp dụng được cho mọi lĩnh vực phát hiện gian lận, do chúng phụ thuộc vào những đặc trưng cụ thể vốn không phải lúc nào cũng có sẵn. Tuy nhiên, trên thực tế, các đặc trưng dạng mốc (landmark features), đặc trưng dạng ràng buộc (constraint features) và đặc trưng tổng hợp (aggregated features) thường được lựa chọn từ tập hợp các thuộc tính phổ biến, bao gồm: thời gian, số tiền, quốc gia, danh mục người bán, ID khách hàng và loại giao dịch.



Hình 3.2: Phát hiện gian lận có nhận biết ngữ cảnh dựa trên kinh nghiệm chuyên gia.

Biểu diễn tự động


Một nhóm các phương pháp nhận biết ngữ cảnh khác coi chuỗi dữ liệu là đầu vào trực tiếp cho mô hình và để mô hình tự động học các mối liên kết phù hợp nhằm tối ưu hóa việc phát hiện gian lận. Ưu điểm của việc không phụ thuộc vào kiến thức con người để xây dựng các đặc trưng (features) phù hợp là giúp

3.2. XÂY DỰNG MODEL

tiết kiệm nguồn lực tốn kém, đồng thời tạo thuận lợi cho khả năng thích ứng và công tác bảo trì. Hơn nữa, các mô hình có thể được phát triển theo hướng kiến trúc quy mô lớn và tự động học các mối quan hệ biến số cực kỳ phức tạp từ dữ liệu. Tuy nhiên, quá trình này đòi hỏi một tập dữ liệu đủ lớn để có thể xác định chính xác các mô hình (pattern) liên quan; nếu không, các biểu diễn đặc trưng thu được sẽ thiếu độ chính xác hoặc không mang lại nhiều giá trị hữu ích.

Một kỹ thuật cơ bản để tự động sử dụng dữ liệu ngữ cảnh là khai thác toàn bộ chuỗi giao dịch (ví dụ: chuyển đổi chuỗi thành một tập hợp các đặc trưng), nhưng cách làm này lại loại bỏ thông tin về thứ tự và có thể dẫn đến không gian đặc trưng có số chiều rất lớn. Một chiến lược phổ biến hơn bao gồm: (1) chuyển đổi các chuỗi thành chuỗi có kích thước cố định và (2) sử dụng một nhóm mô hình đặc biệt có khả năng xử lý chuỗi một cách tự nhiên, đồng thời tóm tắt chúng thành các biểu diễn dạng vectơ phù hợp cho việc phân loại gian lận.

Chiến lược này thường được gọi là học tuần tự (sequential learning) - lĩnh vực nghiên cứu các thuật toán học dành cho dữ liệu có tính tuần tự. Mối quan hệ phụ thuộc về mặt trình tự giữa các điểm dữ liệu được học ở cấp độ thuật toán.



Hình 3.3: Phát hiện gian lận có nhận biết ngữ cảnh dựa trên biểu diễn tự động.

3.2. XÂY DỰNG MODEL

3.2.2 Xử lý dữ liệu

Bước đầu tiên là thiết lập độ dài chuỗi. Sau đó, nhóm các phần tử của dataframe giao dịch theo Mã khách hàng (Customer ID) và sử dụng hàm 'shift' để xác định các giao dịch đã diễn ra trước đó.


Sau đó, tạo các chỉ số giao dịch trong quá khứ của cùng một Customer ID, nhằm xây dựng chuỗi giao dịch (sequence) cho mô hình phát hiện gian lận theo thời gian.

Sử dụng chiến lược padding bằng các giá trị không (zero padding) là mặc định. Độ dài của chuỗi là 5 (tại mỗi chỉ số giao dịch, xem xét 5 giao dịch gần nhất). Chọn batch size là 64, thì tại x batch của tập training sẽ thu được kích thước là [64, 15, 5] (số lượng mẫu tức là batch size là 64, số lượng đặc trưng là 15 trường dữ liệu cho mỗi giao dịch, mỗi mẫu gồm 5 giao dịch gần nhất).

3.2.3 Cấu trúc mô hình

Tiến hành xây dựng mô hình với encoder sử dụng long short-term memory (LSTM). Việc lựa chọn vectơ ngữ cảnh (context vector) phù hợp sẽ dựa trên trực giác về loại ngữ cảnh nào mang lại ý nghĩa trong việc chọn ra các trạng thái ẩn (hidden states) thích hợp của chuỗi. Một lựa chọn hợp lý là sử dụng biểu diễn của giao dịch cần phân loại (giao dịch cuối cùng) làm ngữ cảnh để chọn lọc các thành phần thích hợp từ những giao dịch trước đó. Có hai phương án khả thi: sử dụng trực tiếp trạng thái ẩn cuối cùng làm vectơ ngữ cảnh, hoặc sử dụng một phép chiếu của giao dịch cuối cùng (ví dụ: sau khi áp dụng lớp 'torch.nn.Linear'). Dưới đây, chúng tôi chọn phương án thứ hai; phương án này được thể hiện trong kiến trúc tổng thể như sau:

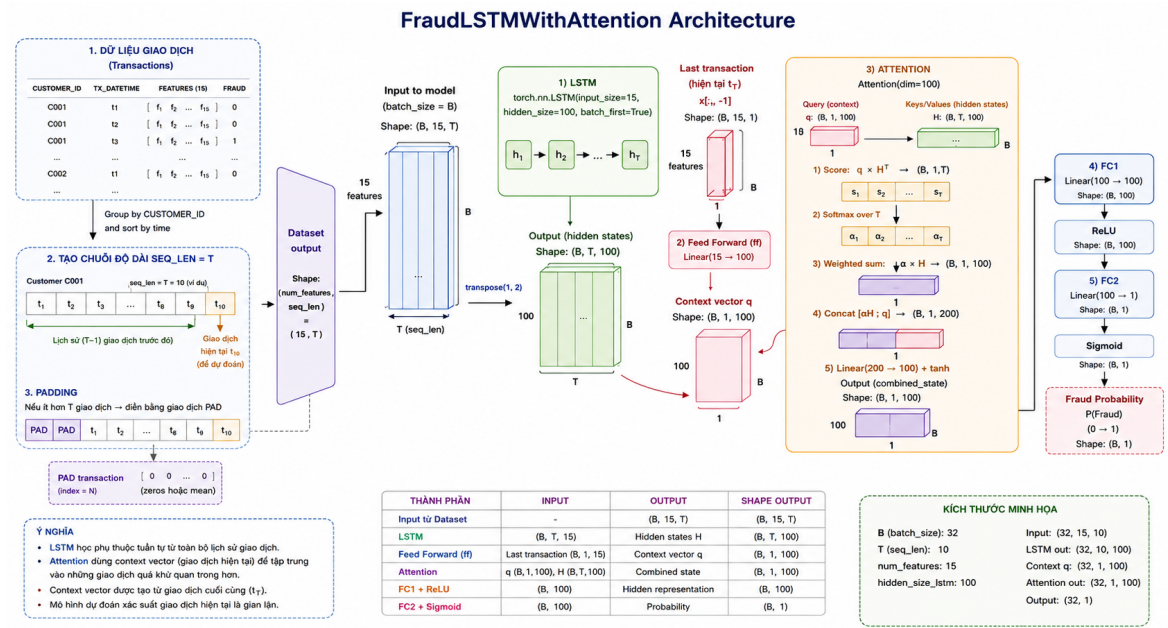
3.2. XÂY DỰNG MODEL



Hình 3.4: Attention trong phát hiện gian lận.

Ngoài ra, để cho phép lựa chọn linh hoạt các trạng thái ẩn (hidden states) phù hợp cho mẫu dữ liệu đang xét, các điểm số chú ý (attention scores) còn mang lại khả năng diễn giải bằng cách hiển thị những phần của chuỗi được sử dụng cho dự đoán hiện tại.

3.2. XÂY DỰNG MODEL



Hình 3.5: Cấu trúc mô hình.

LSTM xử lý chuỗi các giao dịch theo thứ tự thời gian, đóng vai trò encoder. Sau đó là attention mechanism sử dụng thông tin từ các trạng thái của LSTM để tập trung vào những giao dịch/thời điểm quan trọng đối với việc phát hiện gian lận. Cuối cùng là classification head thay vì sử dụng decoder theo encoder - decoder truyền thống.

3.2.4 Grid search trên LSTM với attention

Để lựa chọn cấu hình tối ưu cho mô hình LSTM kết hợp với cơ chế attention, phương pháp grid search được sử dụng nhằm khảo sát các tổ hợp siêu tham số khác nhau. Việc kết hợp toàn bộ các giá trị trên cho phép grid search đánh giá có hệ thống nhiều cấu hình mô hình, từ đó xác định bộ siêu tham số phù hợp nhất dựa trên hiệu suất của mô hình trên tập validation:

- Batch size: [64,128,256]
- Tốc độ học ban đầu (initial learning rate): [0.0001, 0.0002, 0.001]

3.3. HIỆU SUẤT MÔ HÌNH

- Số lượng epoch: [5,10,20]
- Tỷ lệ dropout: [0, 0.2, 0.4]
- Kích thước của trạng thái ẩn LSTM (dimension of the LSTM hidden states): [100,200]

3.3 Hiệu Suất Mô Hình

So sánh hiệu suất của mô hình cơ sở (baseline model) là Random Forest và XGBoost, so với hiệu suất của mô hình sử dụng LSTM với attention.

Bảng 3.1: So sánh hiệu suất của các mô hình dự báo gian lận giao dịch.

Metric	Random Forest	XGBoost	LSTM with Attention
AUC ROC	0.870 ± 0.02	0.869 ± 0.01	0.874 ± 0.02
Average Precision	0.678 ± 0.01	0.687 ± 0.01	0.667 ± 0.01
Card Precision@100	0.299 ± 0.01	0.303 ± 0.01	0.295 ± 0.01

Tài liệu tham khảo

- [1] Yann-Aël Le Borgne, Wissam Siblini, Bertrand Leblot, and Gianluca Bon-
tempi. *Reproducible Machine Learning for Credit Card Fraud Detection -
Practical Handbook*. Université Libre de Bruxelles, 2022.